

# Welche Rolle spielen künstliche Intelligenz und Machine Learning bei der Optimierung von Energieversorgungssystemen?

**Zusammenfassung**—Die Optimierung von Energieversorgungssystemen ist angesichts der steigenden Nachfrage nach effizienter, zuverlässiger und nachhaltiger Energieversorgung von großer Bedeutung. In diesem Zusammenhang spielen künstliche Intelligenz (KI) und maschinelles Lernen (ML) eine immer wichtigere Rolle. Dieser Artikel untersucht die Rolle von KI und ML bei der Optimierung von Energieversorgungssystemen. Es werden verschiedene Anwendungen von KI und ML vorgestellt, darunter Prognose und Optimierung, Lastmanagement und Nachfragesteuerung, Anlagenüberwachung und Wartung, Integration erneuerbarer Energien sowie Energieeffizienz und Verbraucherempfehlungen. Darüber hinaus werden die Herausforderungen diskutiert, die mit der Optimierung von Energieversorgungssystemen verbunden sind, wie die Komplexität der Systeme, die Volatilität erneuerbarer Energien, die Skalierbarkeit und Flexibilität, die Sicherheit und Zuverlässigkeit sowie die wirtschaftlichen und regulatorischen Aspekte. Die Erkenntnisse dieser Arbeit tragen dazu bei, das Verständnis für die Rolle von KI und ML bei der Optimierung von Energieversorgungssystemen zu vertiefen und zeigen Potenziale sowie Herausforderungen auf, die bei der Einführung dieser Technologien berücksichtigt werden sollten.

**Index Terms**—Künstliche Intelligenz, Energieversorgungssysteme, KI, AI, Neuronale Netze, Machine Learning, Maschinelles Lernen

## I. EINLEITUNG

### A. Hintergrund und Motivation des Themas

Die Energieversorgungssysteme stehen heutzutage vor einer Vielzahl von Herausforderungen. Der steigende Energiebedarf, die begrenzte Verfügbarkeit konventioneller Energieressourcen und die zunehmende Bedeutung erneuerbarer Energien erfordern innovative Lösungen, um die Effizienz und Nachhaltigkeit der Energieversorgung zu verbessern. In diesem Zusammenhang spielen künstliche Intelligenz (KI) und maschinelles Lernen (ML) eine immer wichtigere Rolle.

Die Grundidee hinter dem Einsatz von KI und ML in der Optimierung von Energieversorgungssystemen besteht darin, dass diese Technologien in der Lage sind, große Mengen an Daten zu analysieren, Muster zu erkennen, Vorhersagen zu treffen und adaptive Entscheidungen zu treffen. Dadurch können Energieversorgungssysteme effizienter gestaltet, die Zuverlässigkeit erhöht und Kosten gesenkt werden.

Ein zentrales Anwendungsgebiet von KI und ML liegt in der Prognose von Energieerzeugung und -nachfrage. Durch den Einsatz von ML-Algorithmen können präzisere Vorhersagen über den zukünftigen Energiebedarf gemacht werden, was eine optimierte Planung der Energieerzeugung und -verteilung

ermöglicht. Darüber hinaus können ML-Modelle genutzt werden, um Lastmanagement-Strategien zu entwickeln, um den Energieverbrauch zu optimieren und die Spitzenlasten zu reduzieren.

Ein weiteres wichtiges Einsatzgebiet von KI und ML liegt in der Optimierung von Stromnetzen und -verteilung. Hier können intelligente Algorithmen eingesetzt werden, um den Energiefluss zu steuern, Engpässe zu identifizieren und die Netzstabilität zu gewährleisten. ML kann auch bei der Erkennung von Fehlern und Störungen in Energieversorgungssystemen helfen, indem Anomalien in den Daten erkannt und potenzielle Probleme frühzeitig gemeldet werden.

Die Integration erneuerbarer Energien stellt ebenfalls eine große Herausforderung dar, da sie von Natur aus volatil und schwer vorhersehbar sind. Hier kommen KI und ML zum Einsatz, um Vorhersagemodelle für die Stromerzeugung aus erneuerbaren Quellen zu entwickeln, um die Integration in das Gesamtsystem zu optimieren. Dies ermöglicht eine bessere Ausnutzung erneuerbarer Energien und eine verbesserte Integration mit konventionellen Energiequellen.

Neben den technischen Aspekten gibt es auch weitere wichtige Faktoren, die bei der Optimierung von Energieversorgungssystemen berücksichtigt werden müssen. Datenschutz und Sicherheit spielen eine entscheidende Rolle, da die Verarbeitung großer Mengen an Energie- und Verbrauchsdaten eine Herausforderung für den Schutz sensibler Informationen darstellt. Darüber hinaus stellen sich auch ethische Fragen, wie beispielsweise der faire Zugang zu Energie oder die Vermeidung von Diskriminierung bei der Nutzung von KI-gesteuerten Energiesystemen.

In Anbetracht all dieser Aspekte ist es von großer Bedeutung, die Rolle von KI und ML bei der Optimierung von Energieversorgungssystemen zu untersuchen. Durch die Nutzung des Potenzials dieser Technologien können wir eine effizientere, nachhaltigere und zuverlässigere Energieversorgung erreichen. In dieser Seminararbeit werden wir die verschiedenen Einsatzbereiche von KI und ML in der Energieversorgung untersuchen und ihre Auswirkungen sowie mögliche Herausforderungen und zukünftige Entwicklungen analysieren.

## II. GRUNDLAGEN DER KÜNSTLICHEN INTELLIGENZ UND MACHINE LEARNING

### A. Neuronale Netze

Künstliche neuronale Netze sind die Grundfunktionsweise von Systemen, welche künstliche Intelligenz nutzen. Diese Netze bestehen aus einer großen Menge an Neuronen, welche, genauso wie die Neuronen im menschlichen Gehirn, eine Vielzahl an Daten verarbeitet. In der folgenden Abbildung ist der




Abbildung 1: Aufbau eines neuronalen Netzes

Ablauf der Arbeitsweise von künstlichen neuronalen Netzen exemplarisch dargestellt: Das Training eines neuronalen Net-




Abbildung 2: Ablauf des Trainings eines neuronalen Netzes

zes beginnt mit dem Bereitstellen der Informationen, welches oft Signale oder Bildpixel sind. Zum Beispiel Handschriften, Gesichter oder Daten von Wetterberichten. Darauf folgt der Aufbau des neuronalen Netzes, hinsichtlich der Anzahl an Hidden-Layers und Neuronen, gefolgt von der Verarbeitung der Eingangsinformationen durch Training mit verschiedenen Lernverfahren. Das Lernverfahren, mit dem geringsten Fehler wird ausgewählt, aus welchem dann die Antwort des neuronalen Netzes in, als Vektor kodierter Form ausgegeben wird.[1]

### B. Typen von Machine Learning Algorithmen

- Unsupervised Learning:** Beim unüberwachten Lernen gibt es keine Zielwerte, sondern das Ziel besteht darin, Muster und Strukturen in den Daten zu entdecken. Für das System liegen lediglich Eingabewerte vor, jedoch nicht die zugehörigen Ausgabewerte, wie beim überwachten Lernen.[2] Das Modell lernt eigenständig, wie es die Daten gruppieren oder Zusammenhänge finden kann. Clustering und Dimensionsreduktion sind Beispiele für unüberwachtes Lernen. Im Folgenden wird Clustering genauer erläutert: Beim hierarchischen Clustering geht es darum, Entfernungen zwischen verschiedenen Punkten zu messen. Eine der einfachsten Arten, die Distanz zu ermitteln ist die sogenannte Manhattan-Funktion. Diese spiegelt den Weg wieder, der gegangen werden müsste, wenn man einem Gitternetz folgt. Betrachtet man die Punkte  $X=(X_1, X_2, \dots)$  und  $Y=(Y_1, Y_2, \dots)$  ergibt sich die folgende Formel:

$$d = \sum_{i=1}^n |X_i - Y_i|$$

$n$  repräsentiert hierbei die Anzahl der verschiedenen Variablen,  $X_i$  und  $Y_i$  sind die Werte der jeweiligen  $i$ -ten Variable.

Eine weitere verbreitete Messung der Entfernung zweier Punkte zueinander ist die euklidische Distanz. Sie basiert auf dem Satz des Pythagoras und ermittelt den Weg über die Wurzel der quadrierten Differenz der Punkte:

$$d = \sqrt{\sum_{j=1}^n (x_j - y_j)^2}$$

[3]

Mithilfe der folgenden Abbildung wird der Unterschied nochmals grafisch dargestellt:




Abbildung 3: Veranschaulichung der Euklidischen gegenüber der Manhattan Distanz

- **Semi-supervised Learning:** Beim halbüberwachten Lernen werden Modelle mit einer Kombination aus markierten und nicht markierten Daten trainiert. Somit agiert semi-supervised learning zwischen unsupervised- und supervised learning. Motivation hinter der Art des Lernens ist der Aufwand und die Kosten, das Anbieten von gelabelten Daten, bei welchen Ein- und Ausgabewerte bekannt sind. [2] Das Modell nutzt die vorhandenen markierten Daten, um Informationen zu generalisieren und die nicht markierten Daten zu nutzen, um weitere Muster zu erkennen.
- **Supervised Learning:** Der Grundgedanke bei supervised Learning ist, dass die Beispiele (Ein- und Ausgabewerte) bekannt sind. Die Aufgabe des Computers gleicht hier dem Auswendiglernen, wobei der Rechner dies deutlich einfacher und schneller schafft als Menschen. Hieraus ergibt sich eine Funktion, mit welcher bei unbekannten Eingabewerten eine sinnvolle Ausgabe erzielt wird. Diese Funktion wird in der künstlichen Intelligenz als Modell bezeichnet. Die Entwicklung des Modells ist ein stetiger Prozess. Die Parameter des Modells werden während der Lernphase immer wieder angepasst, um die Optimalen Werte hierfür zu finden. Der besondere Vorteil am überwachten Lernen liegt darin, dass man die Ausgaben kennt, und somit während des Lernvorgangs das Modell hinsichtlich der Fehleranfälligkeit überprüfen kann. Bewertet wird das Modell dann jedoch mit Daten, die noch nicht bekannt sind, wobei man möglichst versucht, zu vermeiden, eine höhere Fehleranzahl zu haben, als in der Lernphase, genannt Overfitting. Auch Underfitting stellt ein Problem dar, was meist der Fall ist, wenn die Komplexität eines Modells zu niedrig ist.[2]  
Man unterscheidet hierbei zwischen konkreten Ausgabewerten, sowie kontinuierliche Werte. Diese beiden Wertarten bestimmen, ob es sich bei dem supervised-learning Ansatz um eine Klassifikation oder eine Regression handelt. Bei einem kontinuierlichen Ausgangstyp ist es eine Regression, bei einem diskreten Ausgabewert spricht man von einer Klassifikation. Diese Unterscheidung ist nur von den Ausgabetypen abhängig und nicht von den Eingabewerten.[4]
- **Reinforcement Learning:** Reinforcement learning unterscheidet sich grundlegend von den bisher genannten Lernarten. Während bei un-, semisupervised learning, sowie supervised learning immer sehr viele Eingabedaten für das Lernsystem bereitgestellt werden müssen, generiert reinforcement learning diese selbst. Ein sogenannter Agent interagiert hierfür in einer bestimmten Umgebung. Das Ziel des Agenten besteht darin, Aktionen auszuführen, um eine maximale Belohnung zu erhalten. Durch Erfahrungen, Belohnungen und Bestrafungen passt der Agent sein Verhalten an, um optimale Entscheidungen in der Umgebung zu treffen. Dieser Lernansatz ist perfekt für Szenarien, in denen man keine, oder

nur sehr schwierig Trainingsdaten bereitstellen kann. [2]

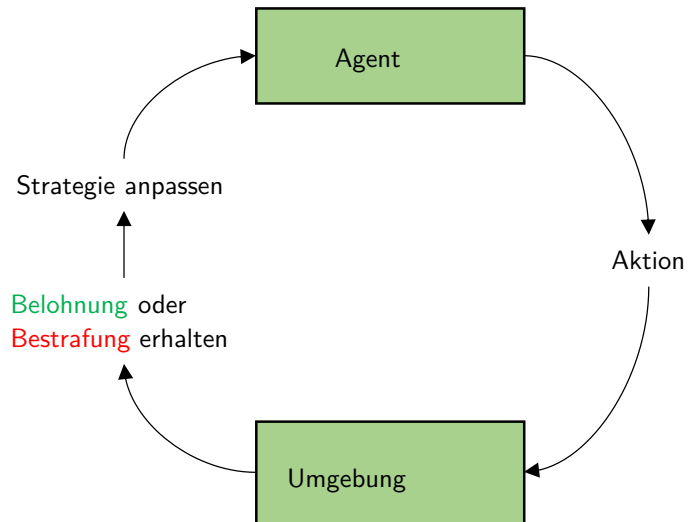


Abbildung 4: Ablauf bei Reinforcement Learning

### III. OPTIMIERUNG VON ENERGIEVERSORGUNGSSYSTEMEN

#### A. Überblick über Energieversorgungssystemen

- **Konventionelle Energieversorgungssysteme:** Konventionelle Energieversorgungssysteme basieren hauptsächlich auf fossilen Brennstoffen wie Kohle, Erdöl und Erdgas. Diese Systeme umfassen thermische Kraftwerke, die die Energie aus der Verbrennung von fossilen Brennstoffen gewinnen, um elektrische Energie zu erzeugen. Sie sind weit verbreitet und haben in der Vergangenheit den Großteil der Energieversorgung abgedeckt.
- **Erneuerbare Energieversorgungssysteme:** Vorallem da konventionelle Energieversorgungssysteme meist auf fossilen Brennstoffen basieren, welche irgendwann ausgeschöpft sein werden, stellt sich die Frage nach neuen Energiequellen, welche sich selbst regenerieren. Erneuerbare Energieversorgungssysteme nutzen natürliche Ressourcen wie Sonne, Wind, Wasser und Biomasse zur Energieerzeugung. Solarenergie wird durch Photovoltaik- oder Solarthermieanlagen gewonnen. Photovoltaikanlagen sind bereits Teil, der meisten Häuser, bei welchen Elektronen durch die Absorption von Photonen in den Halbleitern der Solarzelle frei werden. Die freie, positiv geladene Stelle, welche durch das verlassene Elektron entsteht, füllt sich durch ein neues Elektron, welches dort wieder ein positiv geladenes Loch verursacht. Dieser Prozess wiederholt sich dauerhaft bei Sonneneinstrahlung. Verhindert man diese Entstehung von Elektronen-Loch-Paaren, entsteht eine Spannung. Diese entstandene Spannung kann durch den richtigen Anschluss zum Betreiben elektrischer Geräte mit Strom verwendet werden.[5] Solarenergie kennt man aus dem Alltag, wenn sich Gegenstände, zum Beispiel ein Auto durch Sonneneinstrahlung aufwärmt. Die Sonnenenergie

wird in Form von Wärme im Auto durch die Isolationswirkung von Glas, Blech, etc. gespeichert. In sogenannten Solarkollektoren ist dieser Effekt perfektioniert umgesetzt. Die äußere Hülle bildet eine Schicht Spezialglas, welche darauf ausgelegt ist, möglichst viel Sonnenstrahlen durchzulassen. Darunter befindet sich ein Absorber, welcher aus einem speziellen Material gefertigt ist, um möglichst viel der Strahlen in thermisch hochqualitative Energie umzuwandeln.[6]

Eine weitere Naturkraft, welcher zur Energieerzeugung genutzt wird ist die Windkraft. Die Umsetzung erfolgt in Windrädern, welche sehr einfach aufgebaut sind. Der Wind treibt einen Rotor an, welcher seine Rotationsenergie an einen Generator abgibt, welcher die kinetische Energie dann in verwendbaren Strom umwandelt. Da sich der Wind drehen kann sind die Rotoren auf den Windrädern gelagert, sodass diese immer optimal zum Wind stehen und so möglichst viel kinetische Energie umwandeln können.[7]

Wasserkraftwerke nutzen die Energie des fließenden Wassers. Meist werden hierzu Wehre eingesetzt, welche zwischen beiden Seiten einen Höhenunterschied des Wasserspiegels aufweisen. Dieser Höhenunterschied, wird in Kombination mit der Masse des Wassers genutzt um Turbinen im Wehr anzutreiben. Folgende Gleichung beschreibt hier den Zusammenhang der Kräfte, wobei  $E_{Pot}$  die potentielle Energie des Wassers beschreibt,  $m_{Wa}$  die Masse des Wassers,  $g$  die Gravitationskraft und  $h_{OW}$  den Höhenunterschied der zwei Wasserspiegel.

$$E_{Pot} = m_{Wa} * g * h_{OW}$$

Natürlich ist das nur eine vereinfachte Form der Gleichung. Es spielen noch viele weitere Faktoren eine Rolle, wie die Dichte des Wassers, der Reibkoeffizient des Rohrs oder das Lager der Turbine. All diese Faktoren können sich auf den Wirkungsgrad des Wasserkraftwerkes auswirken.[8]

Biomasseanlagen wandeln organische Materialien in Energie um. Hierbei gibts es sehr unterschiedliche Wirkungsgrade, je nach Pflanzenart, welche verwendet wird.

Tabelle I: Wirkungsgrade bei Produktion von Biomasse

Ozeane	0,07%	Wälder	0,55%
Süßwasser	0,50%	Mais	3,2%
Kulturlandschaft	0,30%	Zuckerrohr	4,8%
Grasland	0,30%	Zuckerrüben	5,4%

Man kann bei der Nutzung von Biomasse sowohl Reststoffe zu Energie umwandeln, als auch extra für die Produktion von Biomasse Pflanzen anbauen. Jedoch geht man in Deutschland von einem Potenzial von ca. 1200PJ/a aus. Daraus lässt sich schließen, dass Biomasse nur einen Teil des Energiebedarfs in Deutschland decken kann. [9]

Diese Systeme sind nachhaltiger und umweltfreundlicher, da sie erneuerbare Ressourcen nutzen und weniger

CO<sub>2</sub>-Emissionen verursachen.

- **Dezentrale Energieversorgungssysteme:** Dezentrale Energieversorgungssysteme zeichnen sich durch eine lokalisierte Energieerzeugung und -verteilung aus. Anstatt auf zentrale Kraftwerke angewiesen zu sein, werden kleine Energieerzeugungsanlagen wie Solaranlagen auf Dächern von Gebäuden oder kleine Windturbinen eingesetzt. Diese Systeme bieten die Möglichkeit, Energie vor Ort zu erzeugen und den Energieverlust durch den Transport über weite Strecken zu reduzieren.
- **Intelligente Energieversorgungssysteme:** Da in den vergangenen Jahrzehnten die Anzahl an erneuerbaren Energieversorgungssystemen extrem gestiegen ist, und auch in Zukunft aufgrund des Klimawandels immer mehr werden wird, werden Möglichkeiten benötigt, die Energie bestens zu verteilen. Eine Herausforderung hierbei ist die Inkontinenz von Energieerzeugung von z.B. Windkraftanlagen begründet durch die schwankende Windstärke. Intelligente Energieversorgungssysteme nutzen fortschrittliche Technologien wie intelligente Netze (Smart Grids), um die Effizienz, Zuverlässigkeit und Integration erneuerbarer Energien zu verbessern. Smart Grids ermöglichen eine bidirektionale Kommunikation zwischen Energieerzeugern, Verbrauchern und dem Netz, wodurch ein optimierter Energiefluss, eine bessere Laststeuerung und die Integration von dezentralen Erzeugungsanlagen möglich sind.[10] Durch den Einsatz von Sensoren, Datenanalyse und Steuerungssystemen können intelligente Energieversorgungssysteme den Energieverbrauch und die Nachfrage besser prognostizieren und optimieren.

### B. Herausforderungen bei der Optimierung

Die Optimierung von Energieversorgungssystemen steht vor einer Reihe von Herausforderungen, die es zu bewältigen gilt. Eine der zentralen Herausforderungen besteht in der Komplexität dieser Systeme. Energieversorgungssysteme bestehen aus einer Vielzahl von Komponenten und Akteuren, wie beispielsweise Energieerzeugung, -übertragung, -verteilung und -verbrauch. Die Koordination und Optimierung all dieser Komponenten erfordert eine umfassende Analyse und Steuerung, um effiziente Ergebnisse zu erzielen.

Ein weiterer wichtiger Aspekt ist die Volatilität erneuerbarer Energien. Die Integration von erneuerbaren Energien wie Solarenergie und Windenergie in das Energieversorgungssystem stellt eine Herausforderung dar. Diese Energiequellen unterliegen starken Schwankungen aufgrund von Wetterbedingungen und weisen volatilere Erzeugungsmuster auf als konventionelle Energieressourcen.

Darüber hinaus stehen Energieversorgungssysteme vor Herausforderungen im Zusammenhang mit der Skalierbarkeit und Flexibilität. Da die Energienachfrage schwankt und sich die Energieerzeugungsmuster ändern, müssen die Systeme in der Lage sein, sich an diese Veränderungen anzupassen und eine zuverlässige Energieversorgung sicherzustellen.

Die Sicherheit und Zuverlässigkeit des Energieversorgungssystems ist eine weitere Herausforderung. Da das Energienetz

ein attraktives Ziel für Cyberangriffe darstellt, müssen Maßnahmen ergriffen werden, um die Systeme vor potenziellen Bedrohungen zu schützen und die Verfügbarkeit der Energieversorgung zu gewährleisten.

Nicht zuletzt sind auch wirtschaftliche und regulatorische Herausforderungen zu berücksichtigen. Die Optimierung von Energieversorgungssystemen erfordert Investitionen in Infrastruktur, Technologien und Forschung. Zudem müssen regulatorische Rahmenbedingungen geschaffen werden, die die Integration neuer Technologien und Geschäftsmodelle ermöglichen und den Übergang zu einer nachhaltigen Energieversorgung unterstützen.

Insgesamt stehen die Optimierung von Energieversorgungssystemen vor verschiedenen Herausforderungen, die von der Komplexität der Systeme über die Integration erneuerbarer Energien bis hin zu Fragen der Sicherheit, Skalierbarkeit und Wirtschaftlichkeit reichen. Die Bewältigung dieser Herausforderungen erfordert einen interdisziplinären Ansatz, der technologische, wirtschaftliche, regulatorische und soziale Aspekte berücksichtigt.

### C. Allgemeine Möglichkeiten der Optimierung

Die Optimierung der Energiesysteme ist in unterschiedliche Bereiche aufteilbar. Zum einen sollte auf die Performance der Systeme geachtet werden. Durch den Mehrverbrauch an Energie im Zuge der Digitalisierung und des Bevölkerungswachstums, ist es von immer größerer Bedeutung, ein sicheres, starkes Energienetz zur Verfügung zu haben. !!!!!GRAFIK EINBINDEN ENERGIEVERBRAUCH!!!! Die Steigerung der Performance kann durch den Ausbau von bereits existierenden Anlagen geschehen, jedoch sollte man auch versuchen, in der Forschung neue Möglichkeiten zu finden, den Wirkungsgrad von Systemen zu erhöhen. Dadurch könnte man dem hohen Flächenverbrauch, durch Solar- und Windparks entgegenwirken.

Ein weiterer Bereich, auf welchen geachtet werden muss, ist die Umweltverträglichkeit der Energieversorgungssysteme. Vor dem Hintergrund des Klimawandels, sollte möglichst vermieden werden, dass große Mengen an  $\text{CO}_2$  und anderen Gasen, durch konventionelle Energieversorgungssysteme in die Atmosphäre gelangen. Durch Verbesserung von regenerativen Systemen kann diesem Vorgang vorgebeugt werden.

## IV. ROLLE VON KÜNSTLICHER INTELLIGENZ UND MACHINE LEARNING BEI DER OPTIMIERUNG VON ENERGIEVERSORGUNGSSYSTEMEN

### A. Potenzial und Vorteile von künstlicher Intelligenz und Machine Learning

Künstliche Intelligenz (KI) und maschinelles Lernen (ML) spielen eine immer wichtigere Rolle bei der Optimierung von Energieversorgungssystemen. Diese Technologien bieten innovative Ansätze zur Verbesserung der Effizienz, Zuverlässigkeit und Nachhaltigkeit der Energieerzeugung, -verteilung und -nutzung. In diesem Kontext können KI und ML verschiedene Hauptaufgaben übernehmen.

Ein wichtiger Aspekt ist die Prognose und Optimierung von Energieverbrauch und -erzeugung. Aufgrund der neuartigen Systeme und der inkontinenten Energieerzeugung von erneuerbarer Energie ist es wichtig, bereits heute zu wissen, was morgen an Energie verbraucht und erzeugt wird. Man unterscheidet zwischen zwei den verschiedenen Arten von Prognosen:

- **Verbrauchsprognose:** Bei den Verbrauchern wird an dem Anschlusspunkt an das öffentliche Versorgungsnetz gemessen. Hier gibt es eine sogenannte registrierte Leistungsmessung im Viertelstundenraster, welche bei Verbrauchern angewandt wird, welche mehr als 100.000 kWh/a benötigt. Bei der anderen Messung werden Gewerbe- und Haushaltskunden betrachtet, welche unter 100.000 kWh/a verbrauchen.[11] Diese Messungen dienen als Eingaben für die künstliche Intelligenz, welche daraus Muster ergeben und folglich präzise Prognosen geben kann.
- **Erzeugungsprognose:** Schwieriger ist die Prognose der Erzeugung von Energie, da diese, durch den immer größeren Einfluss von fluktuierenden Energieversorgungssystemen wie Windkraftanlagen beachtet werden muss. Die Vorhersage ist zudem für Netzbetreiber von besonderer Bedeutung, da diese dazu verpflichtet sind, ein kontinuierliches Energieangebot zu bieten. Sollten Sie dies nicht durch eigene Energieversorgungssysteme ermöglichen können, muss der Netzbetreiber von anderen Anbietern Energie zukaufen. [11]

Durch die Analyse historischer Daten können Modelle entwickelt werden, um den zukünftigen Energiebedarf vorherzusagen. Dies ermöglicht eine verbesserte Planung der Energieerzeugung und -verteilung, um Engpässe zu vermeiden und die Effizienz zu maximieren. Zudem können ML-Algorithmen zur Lösung komplexer Optimierungsprobleme eingesetzt werden, beispielsweise zur Optimierung von Energieflüssen in intelligenten Netzwerken oder zur Ressourcenoptimierung in dezentralen Energieversorgungssystemen.

Eine weitere Rolle von KI und ML liegt im Lastmanagement und der Nachfragesteuerung. Durch die Analyse von Echtzeitdaten können Modelle entwickelt werden, um den Energiebedarf in verschiedenen Szenarien vorherzusagen und entsprechende Maßnahmen zur Laststeuerung zu empfehlen. Dies kann die Netzstabilität verbessern und den Bedarf an zusätzlicher Energieerzeugung während Spitzenzeiten reduzieren.

Darüber hinaus können KI und ML zur Überwachung von Energieerzeugungsanlagen und zur frühzeitigen Erkennung von Wartungsbedarf eingesetzt werden. Durch die Analyse von Sensordaten und anderen Betriebsparametern können Modelle entwickelt werden, um Anomalien und potenzielle Ausfälle vorherzusagen. Dies ermöglicht eine proaktive Instandhaltung und verringert die Ausfallzeiten von Anlagen, was zu einer verbesserten Effizienz und Verfügbarkeit führt.

Die Integration erneuerbarer Energien stellt eine weitere Herausforderung dar, die durch KI und ML bewältigt werden kann. Durch die Analyse von Wetterdaten, Netzwerkleistung

und historischen Mustern können Modelle entwickelt werden, um die Vorhersage und Integration erneuerbarer Energien zu verbessern.

Schließlich können KI und ML Verbrauchern dabei helfen, ihren Energieverbrauch zu optimieren und energieeffiziente Entscheidungen zu treffen. Durch die Analyse von Verbrauchsdaten und Verhaltensmustern können personalisierte Empfehlungen gegeben werden, beispielsweise der Einsatz von energieeffizienten Geräten oder die Anpassung des Nutzungsverhaltens.

Insgesamt spielen KI und ML eine entscheidende Rolle bei der Optimierung von Energieversorgungssystemen, indem sie zu einer effizienteren Nutzung von Energie, einer besseren Integration erneuerbarer Energien und einer verbesserten Steuerung von Lasten beitragen. Diese Technologien tragen dazu bei, die Herausforderungen im Energiesektor anzugehen und den Übergang zu einer nachhaltigeren und effizienteren Energieversorgung zu unterstützen.

### *B. Beispiele und Anwendungen von künstlicher Intelligenz und Machine Learning in der Energieversorgung*

In der Energieversorgung bieten künstliche Intelligenz (KI) und maschinelles Lernen (ML) eine Vielzahl von Anwendungen und Beispielen, die zur Optimierung und Effizienzsteigerung beitragen. Eine wichtige Anwendung besteht in der Prognose und Optimierung von Energieverbrauch und -erzeugung. Durch die Analyse historischer Daten und die Anwendung von ML-Algorithmen können Modelle entwickelt werden, die den zukünftigen Energiebedarf prognostizieren und die optimale Nutzung von Energiequellen ermöglichen. Dies hilft Energieversorgungsunternehmen, die Energieerzeugung effizienter zu planen, Engpässe zu vermeiden und die Kosten zu senken.

Ein weiteres Beispiel ist das Lastmanagement und die Nachfragesteuerung. KI und ML ermöglichen eine präzise Vorhersage des Energiebedarfs in Echtzeit. Basierend auf diesen Vorhersagen können intelligente Systeme empfehlen, wann und wie die Energieverteilung optimiert werden sollte, um Spitzenlasten zu reduzieren und die Netzstabilität zu gewährleisten. Durch die Implementierung von Lastmanagementstrategien können Energieversorger die Effizienz verbessern, Kosten senken und die Nachfragesteuerung erleichtern.

Des Weiteren können KI und ML bei der Überwachung und Wartung von Energieerzeugungsanlagen eingesetzt werden. Durch die kontinuierliche Analyse von Sensordaten und Betriebsparametern können Modelle entwickelt werden, um Anomalien und potenzielle Ausfälle frühzeitig zu erkennen. Dies ermöglicht eine proaktive Instandhaltung und reduziert die Ausfallzeiten der Anlagen. Durch die Implementierung von Predictive Maintenance können Energieversorger die Betriebseffizienz steigern, die Wartungskosten senken und die Zuverlässigkeit der Energieerzeugung verbessern.

Die Integration erneuerbarer Energien stellt ebenfalls eine wichtige Anwendung von KI und ML dar. Durch die Analyse von Wetterdaten, Netzwerkleistung und historischen Mustern

können Modelle entwickelt werden, um die Vorhersage und Integration erneuerbarer Energien zu verbessern. KI-gesteuerte Systeme können den Energiefluss optimieren, um die Schwankungen in der erneuerbaren Energieerzeugung auszugleichen und eine stabile und zuverlässige Energieversorgung sicherzustellen.

Ein weiteres Beispiel ist die Nutzung von KI und ML zur Förderung der Energieeffizienz und zur Bereitstellung von Verbraucherempfehlungen. Durch die Analyse von Verbrauchsdaten und Verhaltensmustern können personalisierte Empfehlungen gegeben werden, wie beispielsweise der Einsatz von energieeffizienten Geräten, die Optimierung der Zeitpläne für den Energieverbrauch oder die Identifizierung von Energieeinsparungspotenzialen. Diese personalisierten Empfehlungen helfen den Verbrauchern, ihren Energieverbrauch zu optimieren und energieeffiziente Entscheidungen zu treffen.

Insgesamt bieten KI und ML in der Energieversorgung zahlreiche Anwendungen und Beispiele, die zur Effizienzsteigerung, Kostenoptimierung, Integration erneuerbarer Energien und Verbesserung des Verbraucherverhaltens beitragen. Der Einsatz dieser Technologien ermöglicht es Energieversorgungsunternehmen, sich den Herausforderungen der modernen Energiewelt anzupassen und eine nachhaltigere und effizientere Energieversorgung zu erreichen.

## V. KRITISCHE BETRACHTUNG UND AUSBLICK

### *A. Grenzen und Risiken von künstlicher Intelligenz*

Der Einsatz künstlicher Intelligenz (KI) in Energieversorgungssystemen birgt sowohl Grenzen als auch Risiken, die berücksichtigt werden müssen. Eine der Grenzen liegt in der Qualität und Verfügbarkeit von Daten. KI-Modelle erfordern hochwertige und ausreichende Daten, um zuverlässige Vorhersagen und Entscheidungen treffen zu können. In der Energieversorgung können jedoch Engpässe bei der Datenqualität und -verfügbarkeit auftreten, insbesondere wenn es um spezifische Daten zu erneuerbaren Energien oder Verbrauchsverhalten geht. Eine unzureichende Datenbasis kann die Genauigkeit und Leistungsfähigkeit von KI-Anwendungen beeinträchtigen. Zudem ist umfänglich die Datenbeschaffung für künstliche Intelligenzen das Problem der Privatsphäre. Eine KI funktioniert besser, desto mehr Eingabedaten angeboten werden können. Jedoch birgt eine digitale Datenerfassung, vor allem von persönlichen Daten, zum Beispiel des häuslichen Energieverbrauchs immer das Risiko, dass diese missbräuchlich genutzt werden können. Das würde einen genauen rechtlichen Rahmen benötigen, in welchem Sensordaten für die KI gesammelt werden dürfen. Die einfachste Lösung ist hierbei eine Entwicklung der KI-Systeme, welche ihre Effektivität mit weniger Eingabedaten halten.[12]

Des Weiteren können Sicherheitsrisiken auftreten. KI-Systeme, die mit Energieversorgungssystemen verbunden sind, könnten anfällig für Cyberangriffe sein. Eine Kompromittierung oder Manipulation von KI-Algorithmen könnte schwerwiegende Auswirkungen auf die Energieinfrastruktur haben. Der Schutz der KI-Systeme vor potenziellen Sicherheitsbedrohungen und die Implementierung robuster Sicher-

heitsmaßnahmen sind daher von großer Bedeutung. Zudem ist Energieversorgung nicht nur gefährdet bei einem generellen Angriff auf das System. Hacker können durch gezielte Manipulationen die Entscheidungsfindung der KI unauffällig nach ihren Vorstellungen beeinflussen. [12]

Ein weiterer Aspekt sind die ethischen Überlegungen. KI-Systeme können Entscheidungen treffen, die weitreichende Auswirkungen auf die Energieversorgung und die Gesellschaft haben. Es besteht das Risiko von Vorurteilen, Diskriminierung oder unfairen Entscheidungen, wenn die Algorithmen nicht angemessen trainiert oder kalibriert sind. Es ist wichtig, sicherzustellen, dass KI-Systeme fair und transparent arbeiten, um potenzielle negative Auswirkungen zu vermeiden. Hinter diesen Befürchtungen steht oft die sogenannte Singularity-Debatte. Diese Debatte befasst sich mit dem Gefahr, dass künstliche Intelligenz eines Tages zu mächtig wird. Bestärkt wird dieser Gedanke durch einige bekannte Personen wie Elon Musk. Anhänger der Singularity Debatte begründen ihre Sorgen häufig mit der These, KI-Systeme könnten sich in einigen Jahren selbst weiterentwickeln.[13]

Darüber hinaus besteht das Risiko von Fehlinterpretationen oder Fehlentscheidungen durch KI-Modelle. Obwohl KI-Systeme in der Lage sind, Muster und Zusammenhänge in den Daten zu erkennen, sind sie nicht immun gegen Fehler. Wenn die Trainingsdaten nicht repräsentativ oder unvollständig sind, können die Vorhersagen und Empfehlungen der KI-Systeme ungenau oder fehlerhaft sein. Eine sorgfältige Validierung und Überwachung der KI-Modelle ist daher von entscheidender Bedeutung, um mögliche Risiken zu minimieren.

Zusammenfassend ist es wichtig, die Grenzen und Risiken von künstlicher Intelligenz in Energieversorgungssystemen zu beachten. Dazu gehören Herausforderungen bei der Datenqualität und -verfügbarkeit, ethische Überlegungen, mögliche Fehlinterpretationen oder Fehlentscheidungen von KI-Modellen sowie Sicherheitsrisiken. Durch eine sorgfältige Planung, Überwachung und Implementierung können diese Risiken minimiert und die Vorteile von KI in der Energieversorgung bestmöglich genutzt werden.

## B. Perspektiven

### VI. FAZIT UND AUSBLICK

Die Rolle von künstlicher Intelligenz (KI) und maschinellem Lernen (ML) bei der Optimierung von Energieversorgungssystemen ist von großer Bedeutung. Die Anwendung von KI und ML bietet vielfältige Möglichkeiten zur Effizienzsteigerung, Kostenoptimierung, Integration erneuerbarer Energien und Verbesserung des Verbraucherverhaltens. Durch den Einsatz von KI können Energieversorgungsunternehmen fundierte Entscheidungen treffen, Prognosen erstellen, den Energiefluss optimieren und die Zuverlässigkeit der Energieversorgung verbessern.

Jedoch sind bei der Nutzung von KI in der Energieversorgung auch Herausforderungen zu berücksichtigen. Grenzen wie die Qualität und Verfügbarkeit von Daten, ethische Überlegungen, potenzielle Fehlinterpretationen oder Fehlentscheidungen

von KI-Modellen sowie Sicherheitsrisiken erfordern eine sorgfältige Planung, Überwachung und Implementierung.

Ausblick: Für die Zukunft bieten sich auf dem Gebiet der künstlichen Intelligenz und des maschinellen Lernens in der Energieversorgung zahlreiche Möglichkeiten. Fortschritte in der Datenverfügbarkeit und -qualität werden die Genauigkeit und Leistungsfähigkeit von KI-Modellen verbessern. Eine verstärkte Berücksichtigung ethischer Prinzipien bei der Entwicklung und Implementierung von KI-Systemen wird zu einer fairen und transparenten Nutzung beitragen.

Darüber hinaus könnten Fortschritte im Bereich der Erklärbarkeit von KI-Modellen dazu beitragen, Vertrauen und Akzeptanz in deren Entscheidungen zu fördern. Die Integration von KI-Systemen mit dem Internet der Dinge (IoT) und anderen fortschrittlichen Technologien ermöglicht eine noch intelligentere und effizientere Energieversorgung.

Ein wichtiger Aspekt für den Ausblick ist die kontinuierliche Forschung und Entwicklung auf dem Gebiet der künstlichen Intelligenz und des maschinellen Lernens in der Energieversorgung. Neue Algorithmen, Modelle und Techniken werden entwickelt, um die Herausforderungen anzugehen und die Leistungsfähigkeit von KI-Systemen weiter zu verbessern.

Insgesamt bietet die Kombination von künstlicher Intelligenz und maschinellem Lernen enorme Potenziale für die Optimierung von Energieversorgungssystemen. Mit einer sorgfältigen Betrachtung der Grenzen, Risiken und Chancen können wir eine nachhaltigere, effizientere und zuverlässigere Energieversorgung der Zukunft erreichen.

### LITERATUR

- [1] Sebastian Dörn. *Programmieren für Ingenieure und Naturwissenschaftler*. Springer, 2016.
- [2] Carsten Lanquillon. "Grundzüge des maschinellen Lernens". In: *Blockchain und maschinelles Lernen: Wie das maschinelle Lernen und die Distributed-Ledger-Technologie voneinander profitieren* (2019), S. 89–142.
- [3] T Soni Madhulatha. "An overview on clustering methods". In: *arXiv preprint arXiv:1205.1117* (2012).
- [4] Stephan Matzka. "Unüberwachtes Lernen". In: *Künstliche Intelligenz in den Ingenieurwissenschaften: Maschinelles Lernen verstehen und bewerten*. Springer, 2021, S. 171–197.
- [5] Oliver Renner. "Grundlagen der Solarenergie". In: *Integratives Umweltmanagement: Systemorientierte Zusammenhänge zwischen Politik, Recht, Management und Technik* (2010), S. 553–561.
- [6] Thomas Schabbach und Pascal Leibbrandt. *Solarthermie*. Springer, 2014.
- [7] Wolfgang Osterhage und Wolfgang Osterhage. "Windkraft". In: *Die Energiewende: Potenziale bei der Energiegewinnung: Eine allgemeinverständliche Einführung* (2015), S. 17–21.
- [8] Markus Aufleger u. a. "Stromerzeugung aus Wasserkraft". In: *Erneuerbare Energien: Systemtechnik · Wirtschaftlichkeit · Umweltaspekte* (2020), S. 583–683.

- [9] Volker Quaschnig. *Regenerative Energiesysteme: Technologie–Berechnung–Klimaschutz*. Carl Hanser Verlag GmbH Co KG, 2021.
- [10] Henrik Lund u. a. “From electricity smart grids to smart energy systems—a market operation based approach and understanding”. In: *Energy* 42.1 (2012), S. 96–102.
- [11] Benjamin Deppe und Michael Kurrat. “Künstliche Intelligenz in der Energieversorgung–Anwendung und Grenzen–”. In: *Theorie und Anwendung lernender Algorithmen in den Ingenieurs-und Naturwissenschaften an der TU Braunschweig* (), S. 54.
- [12] Stephan Dreyer und Johannes Schmees. “Künstliche Intelligenz als Richter?—Wo keine Trainingsdaten, da kein Richter–Hindernisse, Risiken und Chancen der Automatisierung gerichtlicher Entscheidungen”. In: *Computer und Recht* 35.11 (2019), S. 758–764.
- [13] Peter Buxmann und Holger Schmidt. “Ethische Aspekte der Künstlichen Intelligenz”. In: *Künstliche Intelligenz: Mit Algorithmen zum wirtschaftlichen Erfolg* (2021), S. 215–229.